

1. Introduction

1.1 Généralités sur la science des données (Data science)

D'une façon générale, la science des données (ou data science) est le mélange entre trois domaines :

.....




Figure 1.1 : La science des données

L'association entre les mathématiques et l'expertise permet de développer la recherche et l'analyse traditionnelle. Concernant le mélange entre l'expertise et la programmation nous permet de développer le domaine du traitement des données (data processing). La troisième association entre la science des mathématiques et celle de la programmation résulte la constitution du domaine de l'apprentissage automatique (machine learning). La figure suivante montre les différentes associations et les relations entre les différents domaines qui constituent la science des données.




Figure 1.2 : Association des domaines de la science des données

Remarque

Il faut savoir que tous ces domaines reposent essentiellement sur une base de données pour pouvoir modéliser, programmer et faire de l'expertise.

1.2 Définition de l'apprentissage automatique

L'apprentissage automatique connu sous le nom de « Machine learning » est l'application des connaissances mathématiques dans la programmation informatique. Il appartient au champ de l'intelligence artificielle. ***Son but est de donner à un algorithme la capacité d'apprendre sans programmer des contraintes ou des règles.*** Ceci n'est pas comme dans le cas de la programmation classique dans laquelle il faudrait programmer des milliers des cas possibles.

1.3 Application de l'apprentissage automatique

D'une façon générale la question classique à poser est : quand on utilise l'apprentissage automatique ? La réponse se résume selon les points suivants :

-

Exemple :

-

Exemple :

-

Exemple :

1.4 Domaines d'application de l'apprentissage automatique

L'application de l'apprentissage automatique atteint différents domaines comme :

-
-
-
-
-
-

2. Implémentation d'un modèle en apprentissage automatique

2.1 Structure des données

Le développement d'une structure de données ou l'élaboration d'une base de données est nécessaire à la construction des modèles d'apprentissage automatique. Elle doit être assez représentative des données présentées à l'entrée. Par conséquent, plus la base est importante en nombre d'exemples, mieux est la performance du modèle. Généralement, la génération de la base ou la collecte des données se fait à partir de notre environnement qui peut être une image médicale, une caractéristique de qualité d'un processus de fabrication, un son de vibration, une donnée financière etc. Cette génération se fait à partir d'un capteur image, capteur industriel, capteur sonore ou des valeurs caractéristiques (cas de la finance). Toutefois, cette collecte donne des paramètres hétérogènes qui peuvent être avec effet significatif ou avec un effet négligeable sur le modèle développé d'un côté. D'un autre côté, cette collecte de données peut contenir des valeurs erronées ou altérés dû à la prise des mesures ou à des mauvaises manipulations. C'est pour cette raison qu'une phase de structuration et de développement des données est obligatoire et à tenir compte pour améliorer les performances du modèle à construire. La figure ci-dessous illustre ces différentes étapes nécessaires pour la préparation de la base de données.




Figure 1.3 : Récupération et structuration des données

2.2 Construction d'un modèle d'apprentissage automatique

Après la collecte des données et la structuration de la base de données, il faut les unifier et les uniformiser. Cette phase est la phase du prétraitement des données. Cette étape influe considérablement sur les performances du modèle. En effet, les variables sont exprimées en ordre de grandeurs différentes et en unités différentes. Pour que ces données reçoivent la même attention dans la phase de construction, elles doivent être normalisées. Il suffit que la base de données est prête, l'étape suivante consiste à utiliser ces données pour ajuster les paramètres du modèle à construire: c'est la phase d'apprentissage. Cette phase est évaluée par la suite avec un critère quantifiable. Si l'objectif n'est pas atteint l'étape d'ajustement se répète pour se rapprocher de l'objectif. Dans le cas où l'objectif d'apprentissage est atteint le modèle est fixé et utilisé pour l'aide à la prise de décision.

Figure 1.4 : Etapes de développement d'un modèle d'apprentissage automatique

3. Apprentissage d'un modèle à apprentissage automatique

La phase d'apprentissage est la phase dans laquelle les paramètres du modèle sont ajustés. Cet ajustement dépend de la manière ou la façon qu'on veut que le modèle apprend. Dans ce cas trois variantes d'algorithme d'apprentissage sont généralement utilisées : l'apprentissage supervisé, l'apprentissage non supervisé et l'apprentissage par renforcement. Une description de ces trois types d'apprentissage est présentée dans la partie suivante afin de mieux comprendre et mieux définir l'utilité de chaque méthode d'apprentissage.

3.1 L'apprentissage supervisé

C'est la technique d'apprentissage la plus courante. Elle s'inspire de l'apprentissage de l'être humain qui se base sur l'apprentissage selon des exemples. Dans le cas pratique cette technique se base sur un ensemble des données formé par des caractéristiques d'entrées ('Features') et des caractéristiques de sortie. Le but de cet algorithme est de faire la prédiction de la ou les sorties à partir des caractéristiques d'entrées. En d'autre termes, c'est de trouver une relation mathématique entre la (ou les) sorties en fonction des caractéristiques d'entrées. Ce qui nous ramène à appeler cette technique par la technique de régression.

Il faut noter que les applications des algorithmes supervisés se concentrent principalement sur le domaine de régression et le domaine de la classification qui sont utilisés dans des applications reconnaissance des images, de reconnaissance vocale, de prédiction des données des séries temporelles, d'aide à la décision dans les processus industriels, etc. Pour mieux expliquer l'utilité de l'application supervisé deux exemples sont présentées dans la partie suivante.

Exemple 1

Soit la base de données suivante qui décrit la valeur d'une voiture en fonction de son âge.

Tableau 1.1 : Base des données de la valeur de la voiture à chaque âge.

Age [mois]	12	24	48	36	60
Valeur [DT]	40	30	21	16	14




Figure 1.5 : Variation de la valeur de voiture [en dt] en fonction de l'âge [en mois]

L'apprentissage supervisé permet de construire un modèle qui décrit la relation :

$$\hat{y} = f(\dots)$$

Par la suite on peut déterminer pour n'importe quelle âge (ou valeur de A qui n'existe pas dans la base) le prix de la voiture. A partir de ce type de raisonnement on entre dans la logique de l'apprentissage automatique.

Exemple 2

Réellement on est dans un cas plus compliqué dans lequel la marque de la voiture, le kilométrage, la puissance et plusieurs autres facteurs interviennent dans le prix. Par conséquent, la relation de la sortie devient :

$$\hat{y} = f(A, B, C, D, \dots)$$

On remarque que le modèle devient plus complexe et par la suite plusieurs paramètres à trouver ou à ajuster. Ceci décrit la régression multiple qu'on peut l'écrire selon l'équation suivante :

$$\hat{y} = f(x_1, x_2, x_3, x_4, \dots)$$

Avec x_i : les caractéristiques d'entrées du modèle.

3.2 L'apprentissage non supervisé

Dans ce cas, la base de données est composée que par des caractéristiques d'entrées seulement. C'est la principale différence avec celle de l'apprentissage supervisé. Cette technique consiste à construire un modèle d'apprentissage automatique capable d'extraire des caractéristiques intrinsèques des entrées du modèles. D'une façon générale,des données (ou clustering des données) est l'utilisation la plus courante de ce type de méthode. Une deuxième application de cette technique est Elle est utilisée dans le cas où l'objectif se concentre sur la réduction des données caractéristiques. En effet, dans certains cas la dimension des données est aussi importante qu'on devrait la réduire. Une troisième application de l'apprentissage non supervisé est la Cette technique permet de trouver s'il existe des données erronées et non conformes dans la base utilisée. Un exemple sera présenté dans la suite pour mieux expliquer son utilité.

Exemple 1

L'exemple suivant montre le groupement d'une base de données selon deux groupements. Cet exemple compte 6 entrées, chacune est caractérisé par deux critères qui sont le poids et la vitesse maximale (tableau ci-dessous).




Figure 1.6 : Exemple de fonctionnement d'un modèle de clustering

Tableau 1.2 : Base des données des caractéristiques de chaque élément.

Vitesse [Km/h]	25	150	120	20	35	100
Poids [Kg]	1.2	800	3000	1.8	40	1500




Figure 1.6 : Représentation du poids [en Kg] en fonction de la vitesse maximale[en Km/h]

Remarque :

Il faut tenir en compte que lorsqu'on associe la classe de chaque observation on parle alors de classification supervisée.

Exemple 2

Dans cet exemple, la prise des échantillons de la valeur de la température d'un four pendant des intervalles de temps fixes. Le tableau suivant donne les différentes valeurs suivantes.

Tableau 1.3: Base des données des valeurs des températures en fonction de l'horaire journalier.

<i>Heure de l'échantillonnage</i>	9h	10h	11h	12h	13h	14h	15h	16h	17h
Température [10^3 °C]	0.38	0.32	0.31	0.25	0.36	0.61	0.78	0.96	1.75




Figure 1.7 : Evolution de la température du four en fonction du temps

Dans ce cas l'anomalie est de détecter par la présence d'un point hors groupe. Ceci permet de conclure qu'il y a un problème de mesure ou un problème de processus.

3.3 L'apprentissage avec renforcement

L'apprentissage avec renforcement consiste à apprendre à un modèle comment se comporter dans un environnement. Dans ce cas les données d'apprentissage viennent de l'environnement et non pas d'une base de donnée. C'est la principale différence avec l'apprentissage supervisé. On a, juste, besoin d'un modèle, on le met dans un environnement et par lui-même il va développer ses données d'entraînement en interagissant avec son environnement.

Pratiquement, l'apprentissage par renforcement nécessite un temps très important lorsqu'on utilise dans le monde réel. C'est pour cela le modèle est lancé dans un monde virtuel. En d'autres termes on fait des simulations pour accélérer le temps d'apprentissage.

Le but de ce type d'algorithme n'est pas de minimiser la fonction erreur mais de maximiser le nombre de récompenses qui sont données par l'environnement au fur et à mesure que le modèle va inter agir avec son environnement.




Figure 1.8 : Fonctionnement d'un modèle à apprentissage avec renforcement

4. Implémentation d'un modèle généralisé en apprentissage automatique




Figure 1.9 : Méthodologie générale de développement d'un modèle d'apprentissage automatique

5. Application des approches utilisées

D'une façon générale les différentes applications des approches présentées dans ce chapitre se résument sur la régression et la classification dans le cas de l'apprentissage supervisé. Cette approche est largement utilisée dans les modèles d'aide à la prise de décision. Concernant la deuxième approche, le groupement connu sous le nom 'clustering', la détection d'anomalie et la réduction des dimensions constituent les principales applications de cette approche. Dans plusieurs cas, l'apprentissage non supervisé est utilisé pour le pré traitement des bases de données. La dernière approche qui est l'apprentissage par renforcement est une approche récente. Elle est utilisée généralement dans les modèles qui sont injectés dans des environnements inconnus. Toutefois, les performances de ce type d'approche restent relativement moyennes. En effet, beaucoup d'études se suivent pour développer et améliorer ce type d'approche qui prévoit de bonnes performances dans le futur.




Figure 1.10 : Application des principales approches de l'apprentissage automatique

6. Outils d'application de l'apprentissage automatique

Actuellement, les principaux outils de mise en œuvre des modèles à apprentissage automatique sont :

- **Python** : utilisé généralement par les informaticiens (développement des programmes et logiciels) et les automaticiens (traitement d'image, traitement de signal, systèmes de commande),
- **Matlab** : utilisé principalement par les automaticiens et les mathématiciens (développement des modèles théoriques et nouvelles méthodologies),
- **R** : utilisé particulièrement par les mathématiciens et surtout les staticiens,
- **Octave** : utilisé fréquemment par les automaticiens et les mathématiciens.

Concernant les plateformes des outils prêts (framework), ils sont représentés principalement par : 'Tensorflow', 'Caffé' et 'CNTK' et plusieurs autres outils.