

1. Introduction

La deuxième application importante de l'apprentissage supervisé est l'application de la classification. Il faut savoir qu'il existe la classification à deux classes appelée..... et la classificationou à k classes. Dans ce cas, la base de données est composée par des couples.....caractérisée par un.....et un Dans ce type d'apprentissage, la méthode de et la méthode des sont les algorithmes les plus utilisés, respectivement dans le cas de la classification binaire et classification à multi classes.

2. La régression logistique

1.1. Structure de la base de données

Si on considère l'application de la détection d'une cellule cancéreuse décrite par la table ci-dessous.on remarque qu'il existe 4 critères qui décrivent une cellule qui peut être maline (1) ou benine(0).

Tableau 3.1 Représentation des exemples des caractéristiques des cellules cancéreuses.

Taille min	Taille max	Volume	Nb pointe	Type (M/B): Maline/Benine	Codage (0/1)
40	90	300	1	B	0
60	68	400	0	B	0
20	32	650	2	B	0
52	50	280	8	M	1
65	75	520	15	M	1
30	45	250	6	M	1

Dans ce cas, la notation ainsi que les notations des dimensions des matrices de la base de données restent les mêmes que celles étudiés dans le cas de la régression.

1.2. Le modèle

Dans ce cas, si on applique un modèle classique (linéaire, quadratique ou polynomial), la sortie prend des valeurs supérieures à 1 et inférieures à (-1). Ce qui complique la procédure de sélection du modèle.On développe alors la notion de la fonction logistique (appelée fonction sigmoïde) notée par σ et s'écrit :

1.3. La fonction coût :

Dans le cas classique de la régression linéaire, la fonction coût $J(\theta)$ représentée par une courbe convexe (qui présente un seul minimum qui est un minimum global). Dans le cas de la régression logistique, la courbe de $J(\theta)$ n'est pas convexe et présente plusieurs minima locaux. Comme le montre la figure suivante, cette caractéristique bloque l'algorithme du gradient descendant au niveau du premier minimum rencontré.



Figure 3.2 : Représentation d'une courbe convexe



Figure 3.3 : Représentation d'une courbe non convexe

La solution à cette problématique consiste à utiliser la fonction Log pour transformer la fonction $J(\theta)$ en une fonction convexe. Ainsi la formulation de la fonction du coût devient :

$$J(\theta) =$$

Remarque :

Il faut tenir compte que deux formes se présentent lorsque $y=0$ et $y=1$ comme suit (en tenant compte que $\sigma(X, \theta) \in [0, 1]$) :

Dans le cas où $y=1$

$$J(\theta) =$$

Dans le cas où $y=0$

$$J(\theta) =$$

L'équation mathématique qui retient les deux formules s'écrit :

$$J(\theta) =$$

1.4. Algorithme de la descente du gradient :

Dans ce cas, la formulation du gradient reste la même ainsi que l'ajustement des paramètres reste aussi le même que pour la régression classique.

$$\frac{\partial J(\theta)}{\partial \theta} =$$

$$\theta =$$

1.5. Résumé des étapes du développement d'un modèle de régression logistique :

Pour conclure, les étapes de calcul et d'ajustement des paramètres d'un modèle de classification sont :

- **Modèle :**

- **Fonction coût :**

- **Gradient :**

- **Algorithme du gradient :**

3. Algorithme du voisin le plus proche (K-NN algorithm)

3.1. Description

C'est un algorithme très simple, qui permet de résoudre les problématiques de classification (>= 3 classes) de manière efficace, noté par K-NN (abréviation des K Nearest Neighbour). Cet algorithme se base sur un ensemble de données composé d'un ensemble

En effet, pour un vecteur d'entrée faisant pas partie de la base initiale, l'algorithme K-NN va chercher les K vecteurs d'entrée les plus proches du vecteur d'entrée considéré. Suite à cela, pour ces K voisins les plus proches, l'algorithme se basera sur leurs classes y_i pour déterminer la classe du vecteur d'entrée considéré.

3.2. Similarités dans l'algorithme K-NN

Selon la description citée, cet algorithme a besoin d'une fonction de calcul de similarité entre les données. Cette similarité est expliquée généralement par la distance entre les observations ou entre les vecteurs : plus la distance est faible entre les vecteurs, plus les observations sont similaires. Il existe plusieurs fonctions de calcul de distances. Notamment, la distance euclidienne, la distance manhattan, la distance de Hamming, la distance de Minkowski, etc.

Généralement, lorsque les données sont de même type quantitatif, la distance euclidienne est utilisée. Dans le cas où les données sont hétérogènes (age, sexe, taille,...), on utilise la distance de Manhattan.

Les équations des distances sont les suivantes :

- Distance Euclidienne :

$$D_{euc}(x, z) =$$

- Distance de Manhattan :

$$D_{man}(x, z) =$$

3.3. Algorithme du K-NN

Les principales étapes de cet algorithme sont les suivantes :

- Sélection de la base de données ' B '.
- _____
- _____

Pour une nouvelle entrée ' X_{new} ' :

- _____.
- _____.
- Prendre les vecteurs y_B des ' K ' observations et :
 - Calculer _____.
 - Calculer _____.
- _____.

Remarques

- 1- *il faut savoir que ce type d'algorithme peut être utilisé dans le cas*
.....
- 2- *Il faut bien choisir K : en effet, si la valeur de K est faible, moins le résultat est efficace. Dans le cas où la valeur de K est importante, l'algorithme risque de tendre vers un problème de sur-apprentissage (risque de mauvaise généralisation).*

3.4. Caractéristiques de l'algorithme K-NN

Les principales caractéristiques de l'algorithme K-NN se résument aux :

- Avantages :
 - _____,
 - _____.
- Inconvénients :
 - _____,
 - Choix délicat de la formulation de la distance et du nombre des k-voisins : il faut essayer plusieurs combinaisons pour avoir des résultats acceptables.

3.5. Exemple :

Dans cet exemple, La base de données présentée au début de ce chapitre est tenu en compte. Soit la nouvelle entrée exprimée par le vecteur $X=(28, 45, 600, 10)$. En se basant sur la méthodologie présentée ci-dessus, trouver la classe de ' X_{new} ' sachant que $k=3$.

Tableau 3.2 : Représentation de la base des cellules cancéreuses.

Ordre	Taille min	Taille max	Volume	Nb pointe	Type (M/B): Maline/Benine	Codage (0/1)
1	40	90	300	1	B	0
2	60	68	400	0	B	0
3	20	32	650	2	B	0
4	52	50	280	8	M	1
5	65	75	520	15	M	1
6	30	45	250	6	M	1

$d1 =$

$d2 =$

$d3 =$

$d4 =$

$d5 =$

$d6 =$

Les trois plus proches voisins sont :

On peut conclure que la sortie spécifique à ' X ' est :

$y =$ ____
