

Chapitre IV : L'apprentissage non supervisé

1. Introduction

L'apprentissage non supervisé est la deuxième technique la plus connue de l'apprentissage automatique. C'est une méthode d'apprentissage dans laquelle au lieu de présenter au modèle un ensemble de couples Entrées-Soties pour faire apprendre, on représente seulement un ensemble d'entrées. Ainsi, le modèle traite la structure de ces données et tente de trouver les relations intrinsèques entre ces entrées. Les applications les plus courantes de l'apprentissage non supervisé sont définies principalement par le groupement (Clustering), la détection des anomalies et la réduction des dimensions. Toutes ces applications seront développées et expliquées le long de ce chapitre.

2. Le groupement (Clustering)

2.1. Principe de base

Le principe de base du clustering consiste à répartir un nombre d'observations dans un espace de façon à regrouper les observations similaires et séparer les observations dissimilaires. La figure ci-dessous définit une représentation d'un nombre d'observations dans un espace à deux dimensions (2D).




Figure 4.1 Représentation des données selon deux dimensions.

Figure 4.1 Représentation des groupements des données.

Dans ce cas, il faut savoir que la base de données est composée seulement par le nombre d'observations (m) qui sont décrite par x_1 et x_2 . Ainsi, la base de données est représentée par la matrice suivante :

$$B = X_B = \begin{bmatrix} & \\ & \\ & \\ & \\ & \end{bmatrix} \quad \text{avec } \dim(X) = [\quad]$$

Dans cette matrice, on ne remarque aucune présence d'une variable de sortie y caractérisant les m observations : c'est la principale différence avec l'apprentissage supervisé.

Remarque

Notons que dans le cas du clustering, on n'a pas établi des classes dans lesquelles on peut répartir les m observations. Dans le cas où les classes sont définies dans la base de données, on parle alors de classification.

2.2. L'algorithme des K-moyennes (K-Means) :

C'est l'algorithme le plus répondu dans le clustering, c'est une technique d'exploration et d'analyse des données. Elle permet de grouper les vecteurs caractéristiques en se basant sur le calcul des distances euclidiennes. Ainsi, le groupement se base alors sur le calcul de la distance minimale entre les vecteurs caractéristiques.

2.2.1 Mode d'application de l'algorithme des K-Moyennes

L'application de l'algorithme des K moyennes se résume principalement sur les étapes suivantes :

- 1- _____.
- 2- _____.
- 3- Répéter les étapes suivantes jusqu'à atteindre la convergence :
 - Calculer.....
 -
 - Affecter
 -
 - Calculer.....
 -
 -
- 4- Arrêter lorsqu'on
-

La figure ci-dessous décrit les différentes étapes de l'algorithme K means.

Figure4.3 : Procédure de l'algorithme des K moyennes

Remarque

Selon les positions prises au hasard par les centroides initiaux, l'algorithme peut converger vers des mauvaises solutions. Pour résoudre cette anomalie, il faut exécuter l'algorithme avec différentes positions des centroides du départ. La solution retenue est celle qui minimise la somme des distances entre les observations d'un cluster et son centroïde.

2.2.2 Exemple d'application

Soit l'exemple suivant de la base de données à deux caractéristiques (x_1 et x_2)

	x_1	x_2
1	1	1
2	1.5	2
3	3	4
4	5	7
5	3.5	5
6	4.5	5
7	3.5	4.5

Dans le cas où $k=2$, on prend aléatoirement 2 centroides (par exemple : $m=1$ et $m=4$).

⇒ $G_1 = (1,1)$

$G_2 = (5,7)$

- **Itération 1 :**

On calcule la distance de tous les points par rapport aux 2 centroides selon le tableau suivant :

Tableau 4.1 Calcul des distances entre les exemples et les centroides.

	x_1	x_2	Distance par rapport à $G_1(1,1)$	Distance par rapport à $G_2(5,7)$
1	1	1		
2	1.5	2		
3	3	4		
4	5	7		
5	3.5	5		
6	4.5	5		
7	3.5	4.5		

A partir de ce tableau i, il faut sélectionner les exemples les plus proches à chaque centroïde en se basant sur le calcul de la distance. Les nouveaux centroides G_1 et G_2 ont les coordonnées suivantes respectives :

- $G_1 (\quad , \quad) \Rightarrow G_1 (,)$

- $G_2 (\quad , \quad) \Rightarrow G_2 (,)$

- **Itération 2 :**

Tableau 4.2 Calcul des distances entre les exemples et les nouveaux centroides de l'itération 2 .

	x_1	x_2	Distance par rapport à G1(,)	Distance par rapport à G2(,)
1	1	1		
2	1.5	2		
3	3	4		
4	5	7		
5	3.5	5		
6	4.5	5		
7	3.5	4.5		

Après calcul des distances, on remarque 2 nouveaux groupes différents des groupes précédents.

Les nouveaux centroides G1 et G2 sont :

G1 (,) => G1(,)

G2 (,) => G2(,)

- **Itération 3 :**

Tableau 4.3 Calcul des distances entre les exemples et les nouveaux centroides de l'itération 3.

	x_1	x_2	Distance par rapport à G1(1.25 , 1.5)	Distance par rapport à G2(3.9 , 5.1)
1	1	1		
2	1.5	2		
3	3	4		
4	5	7		
5	3.5	5		
6	4.5	5		
7	3.5	4.5		

Après les calculs des distances, ce tableau montre qu'il n'y a aucun changement dans la composition de chaque groupement des exemples. En conséquence, les centroides restent les mêmes et on marque l'arrêt de l'algorithme.

3. Détection des anomalies :

3.1 Principe de base :

Le principe de base d'un modèle de détection d'anomalies consiste à détecter un ou des échantillons qui possèdent des caractéristiques différentes ou très éloignées des autres échantillons. Ce principe permet de détecter les observations qui nuisent à la base de données lorsqu'elle est présentée pour les modèles de régression ou pour les modèles de classification. Ce principe permet aussi de développer des applications à des systèmes de sécurité, des systèmes de détection de fraudes bancaires, des systèmes de détection de défaillances dans un processus de production, etc.

La figure ci-dessous montre un exemple de 2 anomalies détectées dans une base à 2 dimensions avec 15 échantillons.



Figure 4.4 : Représentation d'un exemple de présence d'anomalie dans un groupe de données

Généralement, les méthodes utilisées pour la détection des anomalies sont décrites selon 3 catégories : la première catégorie se base sur le calcul de la densité de probabilité, la deuxième se base sur la distance entre les échantillons et la 3^{ème} catégorie se base sur des critères mixtes. Dans cette partie, les bases fondamentales du principe de la première méthode d'algorithme sont considérées et expliquées dans leur principe de calcul.

Ce type de méthode se base sur le calcul des paramètres de la loi de Gauss (loi normale) de chaque variable d'entrée. Ce calcul se base essentiellement sur la moyenne μ et la variance σ ou encore le carré de l'écart type.

- **Cas d'une seule variable x_1 ,**

Dans ce cas l'entrée s'écrit :

$$X = x_1 = \begin{bmatrix} x_1^{(1)} \\ x_1^{(2)} \\ x_1^{(3)} \\ \vdots \\ x_1^{(m)} \end{bmatrix}$$

Caractérisé par sa moyenne noté par μ et sa variance σ^2 qui s'écrivent :

$$\mu = \dots \dots \dots \quad \sigma^2 = \dots \dots \dots$$

On peut écrire que $x_1 \approx N(\quad)$ en d'autres termes : x_1 est distribuée selon la loi normale de moyenne... ..et de variance

On peut alors représenter la densité de probabilité $p(x)$ comme suit :




Figure 4.5 Représentation de la variation de la densité de probabilité de x_1 .

Ainsi, on peut déterminer l'expression de la loi normale de x_1 comme suit :

$$P(x, \mu, \sigma^2) = \dots \dots \dots$$

Exemple




Figure 4.6 Représentation d'un exemple de dispersion d'échantillons selon une loi normal.

Si on fixe ϵ qui représente un seuil minimal de densité acceptée, on peut conclure que si :

Cette figure montre bien que les autres points $x_1^{(1)} \rightarrow x_1^{(15)}$ possèdent des densités de probabilités supérieure à ϵ . Ce qui justifie leur conformité.

- **Cas à multi - variables :**

Dans le cas à plusieurs variables x_i l'estimation de la densité de probabilité reste la même. Dans le cas d'une base de données à 2 variables, la matrice d'entrée X_B s'écrit comme suit :

$$X_B = \left[\begin{array}{c} \vdots \\ \vdots \end{array} \right]$$




Figure4.7 : Représentation de la variabilité des deux entrées

$$x_1 \approx \cdots \dots \dots$$

$$x_2 \approx \cdots \dots \dots$$

Dans ce cas : $P(x) = \cdots \dots \dots$

Dans le cas général, où on a N_E caractéristiques d'entrée, la matrice d'entrée s'écrit :

$$X_B = \begin{bmatrix} x_1^{(1)} & x_2^{(1)} & \dots & x_{n_E}^{(1)} \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{(m)} & x_2^{(m)} & \dots & x_{n_E}^{(m)} \end{bmatrix}$$

On associe à chaque entrée les lois normales suivantes :

$$\begin{cases} x_1 \sim \dots \dots \dots \\ x_2 \sim \dots \dots \dots \\ \vdots \\ x_{n_E} \sim \dots \dots \dots \end{cases}$$

L'expression de la probabilité s'écrit alors :

$P(x) =$

On peut écrire aussi :

$$\dots \dots \dots$$

Avec

$$\sum_{i=1}^N i = 1 + 2 + 3 + \dots + N \quad \text{et} \quad \prod_{i=1}^N i = 1 * 2 * 3 * \dots * N$$

On calcule les $P(x_i ; \mu_i ; \sigma^2_i)$ puis déduire $P(x)$.

Si $P(x) \leq \varepsilon$ alors ce cas est considéré comme anomalie.

3.2 Mode d'application de l'algorithme :

L'application de cette méthode suit les étapes suivantes :

1. Choisir la base de donnée $X_B = \begin{bmatrix} x_1^{(1)} & x_2^{(1)} & \dots & x_{n_E}^{(1)} \\ x_1^{(2)} & x_2^{(2)} & \dots & x_{n_E}^{(2)} \\ x_1^{(3)} & x_2^{(3)} & \dots & x_{n_E}^{(3)} \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{(m)} & x_2^{(m)} & \dots & x_{n_E}^{(m)} \end{bmatrix}$

2. Calculer les paramètres des densités de distributions μ_j et σ^2_j

Selon les formulations suivantes :

$$\mu_j =$$

$$\sigma^2_j =$$

$$\Rightarrow \mu = \begin{bmatrix} \\ \\ \end{bmatrix} \quad \text{et} \quad \sigma^2 = \begin{bmatrix} \\ \\ \end{bmatrix}$$

3. Calculer la densité de probabilité du nouveau point :

.....

3.1. Calculer les probabilités partielles :

.....

3.2. Calculer la probabilité de la nouvelle entrée :

$$P(X(new)) = \dots \dots \dots$$

4. Comparer $P(X(new))$ avec ε :

3.3 Exemple : Détection d'anomalie dans le cas de deux dimensions

Soit la base de données suivante :

x_1	x_2
0,9	2,7
1,8	3,1
1,95	1,5
1,9	1,8
1,7	1,7
1,65	2,5
0,95	1,6
1,1	1,8
1,5	2,2
1,4	2,6
1,05	2,6
1,15	2,5
1,6	1,68
1,5	1,48
1,35	1,9

On fixe $\varepsilon=0.02=2\%$

D'après ce tableau, les valeurs des moyennes de X_1 et X_2 ainsi leurs écartypes sont :

	X_1	X_2
Moyenne (μ_i)		
Ecartype (σ_i)		

Pour les nouvelles entrées comme suit :

Exemple	$X_1(\text{test})$	$X_2(\text{test})$
Test 1		
Test 2		

On calcul leurs probabilités selon la formulation :

$$P(x) = \underline{\hspace{2cm}}$$

- $P(x^{test1}) = P(; ()^2). P(; ()^2) = \underline{\hspace{2cm}}$
- $P(x^{test2}) = P(; ()^2). P(; ()^2) = \underline{\hspace{2cm}}$

On peut conclure que $\underline{\hspace{2cm}}$ est considéré comme une anomalie dans la base puisque sa probabilité est inférieure au seuil minimal ε .

Remarque

Dans le cas où les descripteurs des entrées ne sont pas décrit par une loi normale, on utilise des astuces mathématiques qui se résument principalement sur un changement de variable tel que : $\log(x)$, $\log(x+1)$ ou $\log(x+C)$ avec C est une constante. On peut aussi utilisé les racines de x comme $x^{(1/2)}$, $x^{(1/3)}$ ou $x^{(1/\alpha)}$.

3.4 Modèle généralisé

3.1.1. Principe de base

La forme généralisée de la détection d'anomalie se base sur la distribution gaussienne à multivariées qui est caractérisé par la matrice des moyennes $\mu \in \mathbb{R}^{n_E}$ et la matrice de covariance $\Sigma \in \mathbb{R}^{n_E \times n_E}$ tel que :

$$P(x_{test}, \mu, \Sigma) =$$

Avec :

- $\mu = \begin{bmatrix} \\ \\ \end{bmatrix}$ avec : $\mu_j = \dots \dots \dots$
- Σ Matrice de covariance de X
 $\Sigma = \dots \dots \dots$
-

Sachant que dans le cas général où les variables sont standardisées, la matrice de covariance de Z se calcule comme suit :

$$cov(Z) =$$

Avec Z est de dimension $[m, n_E]$ et $cov(Z)$ est de dimension $[n_E, n_E]$.

Sa forme est selon la figure suivante :

$$\begin{bmatrix} & & \\ & & \\ & & \end{bmatrix}$$

3.4.2. Algorithme de la méthode :

Les étapes nécessaires pour appliquer l'algorithme du modèle généralisé sont :

1. Calcul des paramètres du modèle :
 - La matrice de la moyenne de x_j
 $\mu =$
 - La matrice de covariance :
 $\Sigma =$

2. Calcul de la probabilité de la nouvelle donnée :

$$P(x) =$$

3. Si la probabilité $P(x_{new})$ est inférieure à un seuil définie ε , alors l'observation x_{new} est considérée comme une anomalie :

$$\begin{cases} P(x) \leq \varepsilon : y = 1 \text{ présence d'anomalie} \\ P(x) \geq \varepsilon : y = 0 \text{ absence d'anomalie} \end{cases}$$

3.4.3. Relation entre le modèle original et le modèle généralisé :

Les deux formulations des deux méthodes étudiées pour la détection d'anomalie sont :

L'expression du modèle original qui s'écrit :

$$P(x) =$$

L'expression du modèle généralisé qui s'écrit :

$$P(x; \mu; \Sigma) =$$

Ces deux modèles sont égaux lorsqu'on n'a pas de corrélation entre les variables x_j . En d'autres termes, si la matrice de covariance s'écrit comme suit :

$$\Sigma = \begin{bmatrix} \sigma^2_1 & 0 & 0 & 0 & \dots & 0 \\ 0 & \sigma^2_2 & 0 & \cdot & \dots & 0 \\ 0 & 0 & \sigma^2_3 & 0 & \dots & 0 \\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\ 0 & 0 & 0 & 0 & \cdot & \sigma^2_{NE} \end{bmatrix}$$

Le tableau suivant résume les avantages et les inconvénients du modèle original et le modèle généralisé.

Tableau 4.4 : Avantages et inconvénients du modèle original et du modèle généralisé.

Modèle généralisé	Modèle original
(+)	(+)
(-) _____	(-)
(-) _____	

4. La réduction de dimensions

4.1. Principe

La réduction de la dimension consiste à diminuer la dimension de la base de données dans le but est de simplifier la structure de la base tout en gardant les principales informations. La principale application de cet objectif consiste à simplifier la complexité que présente une base de données ce qui facilite d'une façon considérable la convergence de l'apprentissage des modèles utilisés dans la régression ou dans la classification d'une part et d'autres part, de diminuer le risque de sur apprentissage des modèles (over fitting).

$X_B =$ devient $X_{red} =$

X est de dimension [] devient une nouvelle matrice noté par X_{red} de dimension [].

Avec .

4.2. Algorithme de l'analyse de la composante principale

L'algorithme le plus utilisé dans la majorité des applications est l'algorithme de l'analyse en composante principale ACP (ou PCA principal component analysis). Le principe consiste à projeter les données sur des axes appelés composantes principales en cherchant à minimiser la distance entre les points et leurs projections.




Figure 4.8 : Représentation de trois cas de projection des données

De cette façon, cette méthode permet de réduire la dimension de la base de données tout en conservant au maximum la variance des données.

Pour appliquer ce raisonnement et pour trouver les axes de projection optimale il faut :

- Calculer la matrice de covariance des données,
- Déterminer les vecteurs propres de cette matrice : qui représentent les composantes principales.

Généralement cet algorithme est un module classique intégré dans tous les logiciels mathématiques que ce soit, Python, Matlab ou autres. Toutefois, l'application de la méthode PCA doit tenir en compte la notion de **variabilité** ou de **la variance conservée**. Cette caractéristique est un indicateur de représentativité de la base initiale.

Généralement la variance à conserver varie entre 95% et 99% : moins la variance conservée est faible moins le nombre de dimension est réduit. La figure ci-dessous montre l'allure de variation de la variabilité de la variance en fonction du nombre des composantes.




Figure 4.9 : Représentation de l'allure de variation de la variabilité des données en fonction du nombre de composantes

Remarques

Il faut savoir que

- Cet algorithme utilise que des données standardisées. Il est donc impératif de normaliser la base de données en fonction de la moyenne et de l'écart type de chaque variable selon l'expression suivante :

$$x_i = \frac{x_i - \mu}{\sigma}$$

Les principaux avantages de la méthode PCA se concentrent sur :

- _____
- _____.

Les principaux inconvénients de cette méthode sont résumés aux points suivants :

- _____
- _____
_____.




Figure 4.10 : Relation non linéaire entre deux variables X_1 et X_2 .