

TD3

Exercice 1 : (application et calcul manuel)

Soit la base de donnée suivante qui décrit le comportement sociale, après l'horaire du travail des opérateurs dans une entreprise, selon 4 caractéristiques(x_1 , x_2 , x_3 , et x_4): aller au café, faire des courses (des achats), faire du sport et rester à la maison. Ces caractéristiques sont décrites par un niveau de préférence spécifique à chaque personne.

N°de personne	x_1 (café)	x_2 (courses)	x_3 (sport)	x_4 (maison)
1	Très souvent	non	non	parfois
2	parfois	parfois	souvent	non
3	non	Très souvent	non	parfois
4	souvent	parfois	non	parfois
5	non	Très souvent	non	parfois
6	non	non	Très souvent	parfois

1. Pour rendre ce tableau accessible aux calculs, il faut encoder ces caractéristiques par un pourcentage de préférence de 0% jusqu'à 100%. Donner la nouvelle forme du tableau.

N°de personne	x_1 (café)	x_2 (courses)	x_3 (sport)	x_4 (maison)
1				
2				
3				
4				
5				
6				

Tenant compte du choix de deux centroides G1 et G2 de coordonnées respectives (0.3 , 0.1 , 0.2, 0.6) et (0.2 , 0.2 , 0.6 , 0.5)

2. Donner les coordonnées des nouveau centroides après 1 itération utilisant la distance euclidienne.
3. Donner la condition nécessaire pour passer à la deuxième itération.
4. Donner les coordonnées des nouveau centroides.

Exercice 2 : (le groupement : implémentation, pratique et observations)

1. Implémenter le code qui décrit l'exercice 1 et vérifier par simulation la conformité des résultats des calculs manuels.
2. Donner quelques bases de données utilisées dans le cas du groupement pour exécuter des benchmark.
3. Donner la bibliothèque et les fonctions nécessaires sur python qui permettent d'appliquer l'algorithme K means.
4. Donner les hyper paramètres de l'algorithme K means.
5. Donner une évaluation de cet algorithme en se basant sur les notions de dispersion. Dresser un tableau des résultats des performances selon le choix de la distance.

Exercice 3 : (Détection d'anomalie : implémentation, pratique et observations)

Dans cet exercice, on tient compte de la même base utilisé précédemment. Les réponses aux questions doivent être suivies avec leurs codes sur python.

1. Donner les matrices de paramètres du modèle statistique utilisant l'algorithme classique des calculs des densités de probabilité partielles.
2. Déterminer s'il existe une anomalie dans cette base.
3. Calculer la matrice de covariance de X_B .
4. Donner les niveaux approximatifs des dépendances entre les caractéristiques d'entrées.
5. Pour consolider la base des données, on procède à l'ajout des nouveaux exemples.

Ces exemples sont décrits dans le tableau ci dessous.

N°de nouvelles personne	x_1 (café)	x_2 (courses)	x_3 (sport)	x_4 (maison)
1	85%	15%	0%	0%
2	100%	0%	0%	0%
3	0%	15%	80%	60%
4	40%	15%	40%	40%

6. Dans ce cas déterminer si ces nouvelles valeurs sont acceptables pour insertion dans la base ou non.
7. Donner une proposition pour évaluer si ces nouveaux exemples peuvent être considérés dans les groupements déjà fixés ou non.

Remarque : Donner le compte rendu qui décrit les activités faites dans cet exercice selon le plan suivant : Titre du TP / Date / Objectif du TP / Réponses aux activités et remarques ou observations pour chaque questions / Conclusions.